NetSTAFF

ASIGNACIÓN DE PERFILES TECNOLÓGICOS MEDIANTE DEEP LEARNING NO SUPERVISADO Y AUTOENCODERS

Miguel Ángel Sánchez-Medina Camacho

OBJETIVO DEL PROYECTO

PROBLEMÁTICA	IMPLEMENTACIÓN	OBJETIVO
• Revisar manualmente miles de CVs **es muy ineficiente y se pierde mucho tiempo** • Las búsquedas de candidatos tradicionales por palabras clave **descartan buenos candidatos e ignoran habilidades clave.** • Las primeras fases del proceso de selección introducen **sesgos inconscientes y falta de objetividad.**	• **Los datos se obtienen de perfiles técnicos** reales extraídos de la encuesta anual de **StackOverflow.** • **Utilizamos un Autoencoder** para extraer el "ADN" técnico de cada candidato (Espacio Latente de 16 dimensiones) • **Creamos un sistema híbrido** que combinen reglas de negocio (RRHH) con el cálculo de la similitud del coseno	• **La automatización del proceso para encontrar el match perfecto** entre el proyecto y el candidato rápidamente**.** • Evaluar el conjunto de habilidades reales del desarrollador, yendo mucho **más allá de la simple lectura de un CV.** • **Garantizar un ranking de candidatos 100% objetivo** y libre de sesgos demográficos.

ORIGEN DE LOS DATOS

FUENTE

stackoverflow

Perfiles técnicos reales extraídos de la encuesta de 2025

VOLUMEN

+ 35.000

Posibles candidatos y 217 variables extraídas como lenguajes, tecnologías, etc.



PROCESAMIENTO DE LOS DATOS

1. Limpieza

- Tratamiento de nulos (NaN) mediante imputación selectiva
- Eliminación de ruido y caracteres especiales
- Filtrado de prefiles inconsistentes

2. Extracción

- Parsing de cadenas complejas (Ej: Python,SQL,AWS)
- Generación de 217 variables únicas binarias

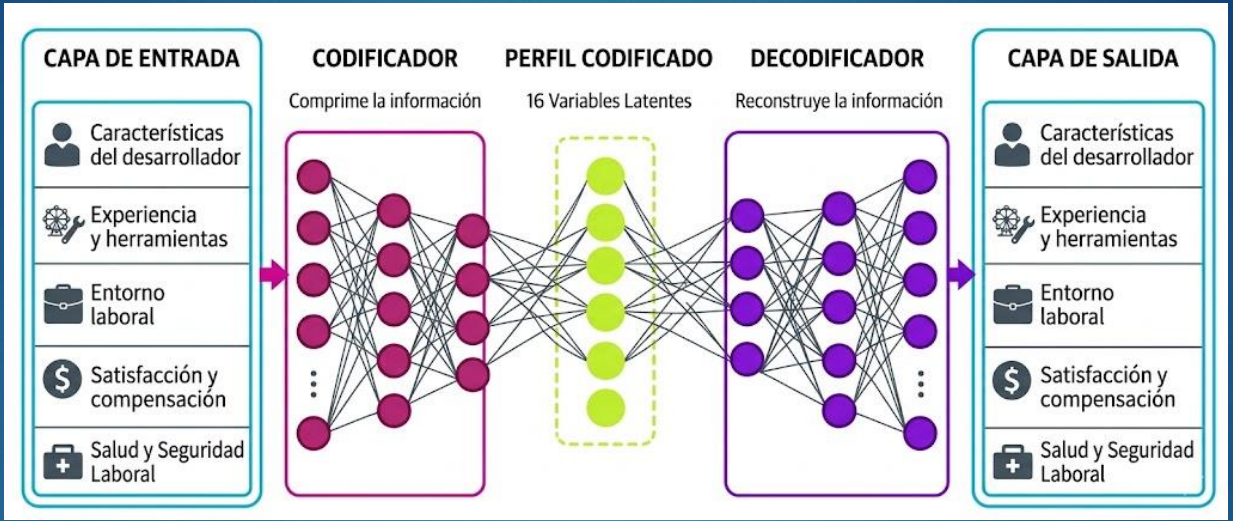
3. Transformación

- Binarización estricta [0,1]
- Normalización de los datos de experiencia mediante escalado MinMax
- Filtrado de prefiles inconsistentes

4. Validación PCA

- Visualizamos los datos en 2D
- Estudiamos la varianza explicada y acumulada
- Justificación empírica del uso de Deep Learning.

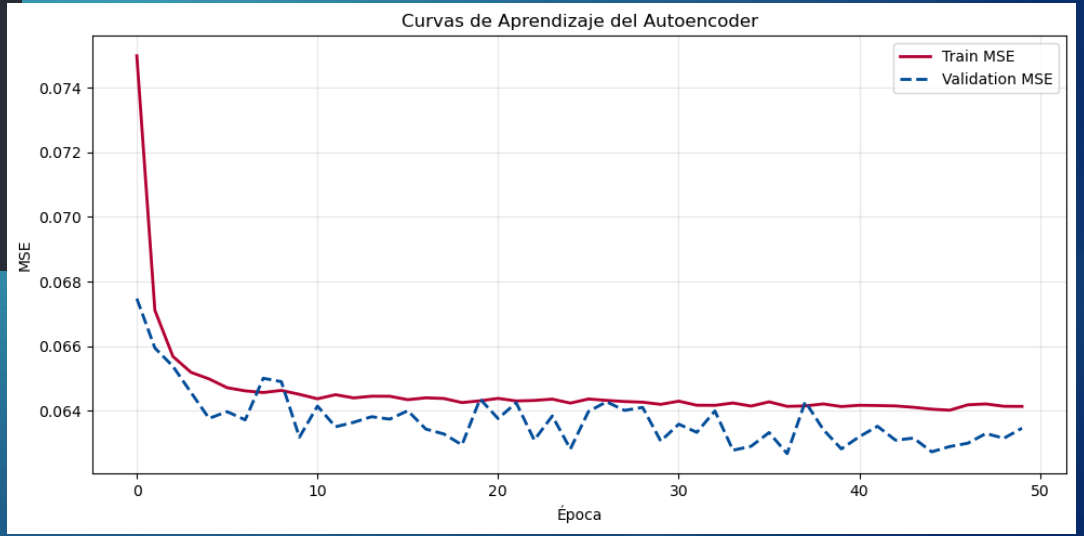
AUTOENCODER



- Arquitectura Simétrica (217 → 128 → 64 → 32 → 16 → 32 → 64 → 128 → 217)
  - Compresión a un espacio latente de 16 variables.
  - ReLU y Sigmoide
- Estrategia de Entrenamiento
  - Split de Datos: 80% Train / 20% Validación.
  - Robustez: Dropout (20%) y Regularización L2 para evitar overfitting

VALIDACIÓN DEL ENTRENAMIENTO

```
Probando configuración: LR=0.001 | Latent_Dim=16
Epoch [01/50] | Train MSE: 0.0833 | Val MSE: 0.0658
Epoch [05/50] | Train MSE: 0.0618 | Val MSE: 0.0600
Epoch [10/50] | Train MSE: 0.0608 | Val MSE: 0.0588
Epoch [15/50] | Train MSE: 0.0605 | Val MSE: 0.0587
Epoch [20/50] | Train MSE: 0.0601 | Val MSE: 0.0589
Epoch [25/50] | Train MSE: 0.0599 | Val MSE: 0.0585
Epoch [30/50] | Train MSE: 0.0597 | Val MSE: 0.0580
Epoch [35/50] | Train MSE: 0.0596 | Val MSE: 0.0580
Epoch [40/50] | Train MSE: 0.0595 | Val MSE: 0.0577
Epoch [45/50] | Train MSE: 0.0594 | Val MSE: 0.0577
Epoch [50/50] | Train MSE: 0.0593 | Val MSE: 0.0574
✅ Entrenamiento finalizado. Mejor modelo restaurado.
Mejor MSE de Validación para esta config: 0.0574
```



ALGORITMO DEL MATCH

El núcleo de NetSTAFF reside en la comparación geométrica de perfiles dentro del **espacio latente de 16 dimensiones**:

- **Inferencia**: Convertimos la oferta ideal en un vector de 16 dimensiones.
- **Cálculo de similitud**: Aplicamos la similitud del coseno entre la oferta y la base de datos
- **Ranking final**: Ordenamos los resultados por cercanía angular.

$$\text{Similitud}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \, \|B\|}$$

Mide la distancia semántica, no el texto plano.

DEMO DEL SISTEMA

```
 OFERTA: Empresa FinTech busca Data Engineer / Backend
 REQUISITOS: Python, SQL, AWS, Experiencia Senior (>0.7)
============================================================

TOP 5 CANDIDATOS:

 RANKING #1 | Perfil A | Nivel de Match: 100.00%
    * Tecnologías clave: JavaScript, HTML/CSS, SQL, Python, Java, PowerShell, C
    * Plataformas/Nube: Stack Overflow, Reddit, Stack Exchange
    * Nivel de Experiencia: 0.77 (Escalado)
------------------------------------------------------------
 RANKING #2 | Perfil B | Nivel de Match: 98.78%
    * Tecnologías clave: SQL, Java, C#
    * Plataformas/Nube: Microsoft Azure, Stack Overflow, GitHub (public projects, not private repos), Stack Exchange
    * Nivel de Experiencia: 0.71 (Escalado)
------------------------------------------------------------
 RANKING #3 | Perfil C | Nivel de Match: 98.66%
    * Tecnologías clave: HTML/CSS, SQL, Bash/Shell (all shells), C#, C++, C, Kotlin, Assembly
    * Plataformas/Nube: npm, Microsoft Azure, Maven (build tool), Gradle, Discord, Twitch
    * Nivel de Experiencia: 0.77 (Escalado)
------------------------------------------------------------
 RANKING #4 | Perfil D | Nivel de Match: 98.64%
    * Tecnologías clave: JavaScript, SQL, Bash/Shell (all shells), Java, PowerShell, PHP
    * Plataformas/Nube: Stack Overflow, GitHub (public projects, not private repos), YouTube, Stack Exchange, LinkedIn
    * Nivel de Experiencia: 0.74 (Escalado)
------------------------------------------------------------
 RANKING #5 | Perfil E | Nivel de Match: 97.80%
    * Tecnologías clave: HTML/CSS, SQL, Python, Bash/Shell (all shells), Java, PowerShell, Rust
    * Plataformas/Nube: Stack Overflow, YouTube, Stack Exchange, Discord, Substack
    * Nivel de Experiencia: 0.77 (Escalado)
```

FUTUROS PASOS



INDEED

Stack Overflow Annual Developer Survey

2025

The 2025 Developer Survey is the definitive report on the state of software development. In its fifteenth year, Stack Overflow received over 49,000+ responses from 177 countries across 62 questions focused on 314 different technologies, including new focus on AI agent tools, LLMs and community platforms.

View Survey Results • Download Full Data Set (CSV)

Past Years

2024	View Results • Download Full Data Set (CSV)
2023	View Results • Download Full Data Set (CSV)
2022	View Results • Download Full Data Set (CSV)
2021	View Results • Download Full Data Set (CSV)
2020	View Results • Download Full Data Set (CSV)
2019	View Results • Download Full Data Set (CSV)
2018	View Results • Download Full Data Set (CSV)
2017	View Results • Download Full Data Set (CSV)
2016	View Results • Download Full Data Set (CSV)
2015	View Results • Download Full Data Set (CSV)
2014	View Results • Download Full Data Set (CSV)
2013	View Results • Download Full Data Set (CSV)

GRACIAS

¿Alguna pregunta?